



Le marché mondial du travail recherche activement des profils *tech* qui s'adaptent aux évolutions rapides. Pour répondre à cette demande, le centre de formation AI/DEV propose deux types de formations, autorisées par le Ministère de l'Enseignement Technique et de la Formation Professionnelle de Madagascar :

- Une formation diplômante de Développeur Web (DTS) sur deux ans.
- Des formations certifiantes sous forme de modules, axées principalement sur l'intelligence artificielle. D'une durée d'une semaine à un mois, ces modules incluent des ateliers pratiques pour garantir l'opérationalité des apprenants.

Data Labeling

(Annotation de données)

Dr MICHEL-RANDRIAMBOLOLONA Nivo



Docteur en Sciences Cognitives et Applications (*Université d'Antananarivo - Madagascar*)




Diplômée en Informatique (*Universität des Saarlandes- Allemagne*)

Certifiée (US) en Deep Learning par DeepLearning.AI

Certifiée (US) en Data Science par IBM

1. DATA LABELING





(supervisé)

Training Set $\mathcal{S} = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$

(non supervisé)

Training Set $\mathcal{S} = \{(x_1), (x_2), \dots, (x_n)\}$

2. LES TACHES BASIQUES PRISES EN CHARGE PAR L'IA

TEXTE		
Classification de texte	Attribuer une ou plusieurs catégories à un bloc de texte.	<i>Exemple:</i> Classer un e-mail comme "spam" ou "non-spam", ou un avis client comme "positif", "négatif", ou "neutre".
Reconnaissance d'Entités Nommées (NER)	Identifier et classer les "entités nommées" dans un texte (personnes, organisations, lieux, dates, etc.).	<i>Exemple:</i> Dans "Elon Musk a visité Paris le 14 juillet", "Elon Musk" (PERSONNE), "Paris" (LIEU), "14 juillet" (DATE).
Traduction	Traduit un texte d'une langue à une autre.	<i>Exemple :</i> Google Traduction traduit "Bonjour, comment ça va ?" en anglais "Hello, how are you?".
IMAGE		
Classification d'images	Attribuer une étiquette ou une catégorie à une image entière.	<i>Exemple :</i> reconnaître des images de chiens, de chats et d'oiseaux.
Détection d'objet	Une tâche de vision par ordinateur qui identifie les objets dans une image ou une vidéo, les localise et les classe. Elle peut trouver plusieurs objets dans une même image et dessiner une boîte englobante autour de chacun d'eux, tout en les étiquetant avec leur classe.	<i>Exemple:</i> Tracer un rectangle autour d'une voiture dans une image.
Segmentation 2 types : - Sémantique - Par instance	Une tâche de vision par ordinateur qui divise une image en plusieurs segments ou régions. Le but est de simplifier ou de changer la représentation d'une image en un objet significatif et plus facile à analyser. Chaque pixel de l'image est associé à une classe ou à un objet.	🔍 Voitures autonomes 🚗 : la segmentation permet de distinguer la route, les piétons, les feux de signalisation et les autres voitures. 🔍 Imagerie médicale 🏥 : La segmentation est utilisée pour isoler des organes, des tumeurs ou d'autres anomalies dans les images médicales
AUDIO		
Transcription (Speech-to-Text)	Une technologie qui convertit la parole humaine, qu'elle soit parlée en direct ou dans un enregistrement audio, en un texte écrit.	Turboscrib
VIDEO		
Tracking d'objets dans les vidéos	Suivre la trajectoire d'objets spécifiques à travers différentes images d'une séquence vidéo.	Wondershare Filmora

3. LES FORMATS A CONNAÎTRE

Comprendre les formats de données est essentiel pour le **data labeling** car ils déterminent la manière dont les informations sont structurées, stockées et échangées.

Le format CSV

Le format **CSV** (*Comma-Separated Values*) est le plus simple et le plus couramment utilisé, surtout pour les données tabulaires (comme une feuille de calcul).

- **Structure** : Les données sont organisées en lignes et en colonnes. Chaque ligne représente un enregistrement et les valeurs des colonnes sont séparées par un délimiteur, le plus souvent une virgule (,).
- **Utilisation** : Il est idéal pour les jeux de données simples et structurés, par exemple, une liste de clients avec leurs noms, adresses et numéros de téléphone. C'est le format par défaut des feuilles de calcul comme Excel ou Google Sheets.
- **Avantage** : Il est facile à lire, à comprendre et à manipuler pour les humains comme pour les machines.
- **Inconvénient** : Il ne permet pas de gérer des structures de données complexes ou hiérarchiques.

levelType	code	catalogType	name	description	sourceLink
CATEGORY	Street Lighting	PRODUCT	Street Lighting	Category code for Street Lighting	http://lighttree.com/Street Lighting
CATEGORY	Pedestrian Lighting	PRODUCT	Pedestrian Lighting	Category code for Pedestrian Lighting	http://lighttree.com/Pedestrian Lighting
CATEGORY	Traffic Signal Poles	PRODUCT	Traffic Signal Poles	Category code for Traffic Signal Poles	http://lighttree.com/Traffic Signal Poles
CATEGORY	Controls	PRODUCT	Controls	Category code for Controls	http://lighttree.com/Controls
CATEGORY	Downlights	PRODUCT	Downlights	Category code for Downlights	http://lighttree.com/Downlights
CATEGORY	Retrofit Downlights	PRODUCT	Retrofit Downlights	Category code for Retrofit Downlights	http://lighttree.com/Retrofit Downlights
CATEGORY	Ambient	PRODUCT	Ambient	Category code for Ambient	http://lighttree.com/Ambient
CATEGORY	Bulbs	PRODUCT	Bulbs	Category code for Bulbs	http://lighttree.com/Bulbs

Le format JSON

Le format **JSON** (*JavaScript Object Notation*) est un format de données textuel et hiérarchique qui est très populaire dans le développement web et les API.

- **Structure** : Il est basé sur des paires **clé-valeur** et peut contenir des objets ({}) et des tableaux ([]). Les données peuvent être imbriquées pour créer des structures complexes.
- **Utilisation** : Il est parfait pour des données non-tabulaires et des informations complexes. Par exemple, pour étiqueter des boîtes de délimitation sur une image, on peut stocker le nom du fichier image, une liste d'objets détectés, et pour chaque objet, les coordonnées de la boîte, son type, et son niveau de confiance.
- **Avantage** : Il est flexible, léger et facilement lisible par la plupart des langages de programmation.
- **Inconvénient** : Il peut devenir difficile à lire et à maintenir si la structure devient trop imbriquée.

```

{
  "prenom": "Pierre",
  "nom": "Giraud",
  "adresse": {
    "rue": "30 Impasse des Lilas",
    "ville": "Toulon",
    "cp": 83000,
    "pays": "France"
  },
  "mails": [
    "pierre.giraud@edhec.com",
    "pierre@pierre-giraud.com"
  ]
}

```

Le format XML

Le format **XML** (*eXtensible Markup Language*) est un langage de balisage utilisé pour la gestion de l'information hiérarchique.

- **Structure** : Les données sont organisées à l'aide de **balises** (<tag>) qui définissent la structure et la sémantique de l'information.
- **Utilisation** : Il a longtemps été utilisé pour les applications web, la configuration de logiciels et le stockage de données structurées. Il est encore présent dans certains logiciels, par exemple pour le balisage d'images (comme le format Pascal VOC) ou la création de documents structurés.
- **Avantage** : C'est un format très strict et puissant, permettant de définir des schémas de données précis (via DTD ou XML Schema).
- **Inconvénient** : Il est plus verbeux et moins facile à lire que le JSON. Sa manipulation peut être plus complexe.

```

<?xml version="1.0"?>
<Catalog>
  <Book id="bk101">
    <Author>Garghentini, Davide</Author>
    <Title>XML Developer's Guide</Title>
    <Genre>Computer</Genre>
    <Price>44.95</Price>
    <PublishDate>2000-10-01</PublishDate>
    <Description>An in-depth look at creating applications
    with XML.</Description>
  </Book>
  <Book id="bk102">
    <Author>Garcia, Debra</Author>
    <Title>Midnight Rain</Title>
    <Genre>Fantasy</Genre>
    <Price>5.95</Price>
    <PublishDate>2000-12-16</PublishDate>
    <Description>A former architect battles corporate zombies,
    an evil sorceress, and her own childhood to become queen
    of the world.</Description>
  </Book>
</Catalog>

```